

👉 Quer conhecer o programa da Mentoria e acelerar sua carreira com o MVP Guilherme Maia e mentores? Faça sua aplicação gratuita

FIXADO

<https://forms.highexpert.com.br/aplicacao-mentoria>

📍 Entre no Grupo exclusivo no WhatsApp da Imersão

FIXADO

<https://chat.whatsapp.com/F3hEr28D0WIDIFqeOsqsEh>

DIA 2

NÃO INICIADO

🕒 00:00 tempo esgotado

LAB 13

Azure AI Foundry com configuração segura

Azure AI Foundry com configuração segura

🎯 OBJETIVO

distinguir provisionamento do Foundry da integração de código e validar limites.

📍 ONDE FAZER

Portal Azure / Foundry

Objetivo: validar a rota de recomendações da aplicação no modo demonstração, disponível inclusive em contas Trial, e opcionalmente integrá-la a um recurso Microsoft Foundry/Azure OpenAI aprovado.

Você desenvolverá: modo demonstração sem custo de IA, escolha segura entre recurso existente ou novo, validação de modelo e região, autenticação por Microsoft Entra ID, configuração sem segredos no código, observabilidade e limites de consumo.

Caminho obrigatório — modo demonstração (contas Trial e demais assinaturas):

1. O modo **demo** não chama Azure OpenAI, Foundry, Key Vault ou qualquer modelo externo. Ele gera uma recomendação determinística a partir do catálogo local,

permitindo validar a rota da aplicação sem quota ou custo de IA.

2. Aplique a configuração padrão e reinicie o Deployment:

COMANDO

 Copiar

```
kubectl apply -f ../../infra/k8s/configmap.yaml  
kubectl -n azure-shop rollout restart deployment/azure-shop  
kubectl -n azure-shop rollout status deployment/azure-shop
```

3. Valide a rota sem dados pessoais:

COMANDO

 Copiar

```
kubectl -n azure-shop port-forward service/azure-shop 3000:80  
curl --request POST http://127.0.0.1:3000/api/ai/recommendations \  
  --header "Content-Type: application/json" \  
  --data '{"interest":"quero aprender Azure"}'
```

A resposta deve informar `"model": "demo-local"`. Encerre o `port-forward` com `Ctrl+C`.

Caminho opcional — Azure AI Foundry e Azure OpenAI:

Use este caminho somente quando a assinatura tiver acesso confirmado ao serviço, ao modelo e à quota. Ele não é requisito para concluir o Lab 12 em uma conta Trial.

Pré-Requisitos do caminho Azure:

- RBAC compatível com a ação escolhida: para criar ou administrar o projeto/recurso, uma função como **Foundry Owner** ou **Foundry Account Owner** no escopo adequado; para consumir inferência, a identidade da aplicação ou do usuário precisa da função **Cognitive Services User** no recurso;
- provider `Microsoft.CognitiveServices` registrado na assinatura;
- região, modelo, versão e capacidade disponíveis na assinatura: `[definir]`;
- quota aprovada ou disponível para o modelo e o tipo de deployment: `[definir]`;
- Azure CLI autenticada ou acesso ao Portal/Foundry portal;

- Key Vault disponível caso uma integração não suporte autenticação por identidade gerenciada.

Autenticação e descoberta:

1. Autentique-se e confirme o contexto:

COMANDO

 Copiar

```
az login
az account show
az provider show \
  --namespace Microsoft.CognitiveServices \
  --query registrationState \
  --output tsv
```

2. Use **GitHub Copilot Free com Azure MCP**, se ele estiver disponível e já configurado, somente como assistente de descoberta e orientação. Exemplos de perguntas guiadas:
 - “Quais recursos `Microsoft.CognitiveServices` já existem nesta assinatura e qual é o estado deles?”
 - “Quais roles a identidade gerenciada da aplicação possui no recurso `[definir]`?”
 - “Mostre os passos oficiais para verificar quota e deployments sem revelar chaves.”
3. Revise cada resposta e cada comando antes de executá-lo. Não cole chaves, connection strings, tokens, dados de clientes ou conteúdo de Key Vault no chat.
4. Copilot Free e Azure MCP não são requisitos do Lab. Se não estiverem disponíveis, faça a mesma descoberta pelo Portal, Azure CLI ou Terraform já aprovado pela equipe.
5. A configuração Terraform do Modelo A não cria Foundry/Azure OpenAI: esse Lab usa recurso existente aprovado ou um fluxo separado, autorizado e revisado.

Escolha do recurso e Deployment:

1. No [Microsoft Foundry](https://foundry.azure.com/), localize um projeto e recurso existentes aprovados para a imersão. Registre apenas nomes confirmados:
 - Resource Group: `[definir]`;

- recurso Foundry/Azure OpenAI: `[definir]`;
 - projeto Foundry, se aplicável: `[definir]`;
 - região: `[definir]`.
2. Se não houver recurso existente e houver autorização, use o Portal, Azure CLI ou Terraform documentado pela equipe para criar o recurso. Não crie recursos paralelos apenas para contornar RBAC, quota ou capacidade.
3. No Foundry portal, abra **Discover** > **Models**, selecione somente um modelo que apareça como disponível para a assinatura e região e crie o deployment. Anote:
- nome do deployment: `[definir]`;
 - modelo e versão: `[definir]`;
 - tipo de deployment e capacidade/quota: `[definir]`.
4. Como alternativa via Azure CLI, use os valores confirmados:

COMANDO

 Copiar

```
az cognitiveservices account deployment create \  
  --name "[definir: recurso]" \  
  --resource-group "[definir]" \  
  --deployment-name "[definir]" \  
  --model-name "[definir]" \  
  --model-version "[definir]" \  
  --model-format OpenAI \  
  --sku-name "[definir]" \  
  --sku-capacity "[definir]"
```

5. Confirme o estado do deployment antes de integrá-lo:

COMANDO

 Copiar

```
az cognitiveservices account deployment show \  
  --name "[definir: recurso]" \  
  --resource-group "[definir]" \  
  --deployment-name "[definir]" \  
  --query properties.provisioningState \  
  --output tsv
```

Identidade do Workload no AKS:

1. Com autorização para criar uma identidade gerenciada e atribuir RBAC, crie a identidade para o workload. Registre os valores reais:

COMANDO

 Copiar

```
az identity create \  
  --resource-group "[definir: RG aprovado]" \  
  --name "[definir: identidade do workload]" \  
  --location "[definir: regioao]"
```

2. Obtenha o `principalId`, o `clientId` e o emissor OIDC do AKS:

COMANDO

 Copiar

```
IDENTITY_PRINCIPAL_ID=$(az identity show \  
  --resource-group "[definir: RG da identidade]" \  
  --name "[definir: identidade do workload]" \  
  --query principalId --output tsv)  
  
IDENTITY_CLIENT_ID=$(az identity show \  
  --resource-group "[definir: RG da identidade]" \  
  --name "[definir: identidade do workload]" \  
  --query clientId --output tsv)  
  
AKS_OIDC_ISSUER=$(az aks show \  
  --resource-group "[definir: RG do AKS]" \  
  --name "[definir: AKS]" \  
  --query oidcIssuerProfile.issuerUrl --output tsv)
```

3. Crie a credencial federada para a ServiceAccount `azure-shop-ai`:

COMANDO

 Copiar

```
az identity federated-credential create \  
  --resource-group "[definir: RG da identidade]" \  
  --identity-name "[definir: identidade do workload]" \  
  --name azure-shop-ai \  
  --issuer "$AKS_OIDC_ISSUER" \  
  --subject system:serviceaccount:azure-shop:azure-shop-ai \  
  --audiences api://AzureADTokenExchange
```

4. Atribua o papel **Cognitive Services OpenAI User** somente no recurso Azure OpenAI aprovado:

COMANDO

 Copiar

```
OPENAI_RESOURCE_ID=$(az cognitiveservices account show \
  --resource-group "[definir: RG do Azure OpenAI]" \
  --name "[definir: recurso Azure OpenAI]" \
  --query id --output tsv)

az role assignment create \
  --assignee-object-id "$IDENTITY_PRINCIPAL_ID" \
  --assignee-principal-type ServicePrincipal \
  --role "Cognitive Services OpenAI User" \
  --scope "$OPENAI_RESOURCE_ID"
```

Configuração segura da aplicação: Aplique a Namespace e a ServiceAccount incluídas no repositório. A ServiceAccount é usada pelo Deployment e não contém segredo.

COMANDO

 Copiar

```
az aks get-credentials \
  --resource-group `[definir]` \
  --name `[definir]` \
  --overwrite-existing
```

NÃO É NECESSÁRIO ESSAS ETAPAS ABAIXO

COMANDO

 Copiar

```
cd ~/azureshop
```

COMANDO

 Copiar

```
az acr build \
  --registry "acrimersaoazureshop1" \
  --image "azure-shop:lab12" \
  .
```

COMANDO

 Copiar

```
kubectl apply -f infra/k8s/configmap.yaml

sed \
  's|ACR_NAME.azurecr.io/azure-shop:IMAGE_TAG|acrimersaoazureshop1.azurecr.io/azure-shop:IMAGE_TAG|' \
  infra/k8s/deployment.yaml \
  | kubectl apply -f -

kubectl apply -f infra/k8s/service.yaml
```

ATÉ AQUI NÃO PRECISA FAZER, SOMENTE EM CASOS DE ERROS.

COMANDO

 Copiar

```
kubectl apply -f infra/k8s/namespace.yaml
kubectl apply -f infra/k8s/serviceaccount.yaml
```

COMANDO

 Copiar

```
kubectl -n azure-shop annotate serviceaccount azure-shop-ai \
  azure.workload.identity/client-id="$IDENTITY_CLIENT_ID" \
  --overwrite
```

2. Configure endpoint, deployment e o modo `azure-openai`. Não defina `AZURE_OPENAI_API_KEY`.

COMANDO

 Copiar

```
kubectl -n azure-shop set env deployment/azure-shop \
  AI_ENABLED=true \
  AI_MODE=azure-openai \
```



HIGH EXPERT
Imersão Arquiteto Azure
Edição 5 — Cloud & AI

 Buscar no material... Instrutor

```
kubectl -n azure-shop rollout status deployment/azure-shop
```

3. Nunca exponha chaves no código, no repositório, em `terraform.tfvars`, manifests Kubernetes, imagens de Contêineres, logs ou chat. Este laboratório usa Microsoft Entra ID; se uma integração excepcional exigir segredo, armazene-o no Key Vault e obtenha aprovação antes de usá-lo.

Validação e operação:

1. No playground do Foundry ou em um cliente autenticado por Microsoft Entra ID, envie uma solicitação simples, sem dados sensíveis, ao deployment `[definir]`.
2. Teste a rota da aplicação sem dados pessoais:

COMANDO

 Copiar

```
kubectl -n azure-shop port-forward service/azure-shop 3000:80
curl --request POST http://127.0.0.1:3000/api/ai/recommendations \
  --header "Content-Type: application/json" \
  --data '{"interest":"quero aprender Azure"}'
```

3. Confirme que a resposta é recebida e que o nome do deployment, endpoint e identidade usados correspondem aos valores aprovados.
4. Revise métricas de requisições, tokens, latência e erros no recurso/Foundry. Quando aprovado, conecte a telemetria da aplicação ao Application Insights sem registrar prompts, respostas ou segredos sensíveis.
5. Acompanhe quota, TPM/RPM e respostas `[429]`. A capacidade, os limites e o custo variam por modelo, região, tipo de deployment e consumo; consulte o Portal e a documentação atual antes de definir valores.
6. Defina limites de uso, alertas de custo e uma estratégia de retry com backoff antes de qualquer carga real.

Validação: confirme provider, deployment `[Succeeded]`, identidade/RBAC e chamada sem dados sensíveis somente em ambiente aprovado.

Falhas e contingência: quota/modelo/região indisponível → playground ou demonstração; não prometa integração de código que não foi implementada.

Custo e cleanup: o custo varia por modelo/capacidade/uso. Configure limites e alertas antes de carga real.

Check-in do Lab 13

Você marcou este Lab como concluído. Progresso salvo neste navegador.

**Concluído**[← LAB 12](#)**Build e publicação no AKS**

Imersão Arquiteto Azure — Edição 5 — Cloud & AI

Material oficial da Imersão Arquiteto Azure.



Guilherme Maia

MVP Microsoft

Founder & CEO

© 2026 Todos os direitos reservados. High Expert